Pon un título a tu documento

Introducción a la Ciencia de Datos. Máster en Ciencia de Datos- UV

Pon aquí tu nombre y apellidos

2026-10-20

Índice

1 2 Ejemplo: fichero DFP1_11122015 124700.csv **1**

1.1 2.1 Importación del fichero 1

1.2 2.2 Inspeccion de los datos 2

2 3 Fichero Transactions from a Bakery **3**

3 4 Fichero SPSS PyschBike.sav **5**

3.1 Inspección de los datos 6

4 5 Fichero data iris.zip **7**

4.1 5.1 Descompimir el fichero 7

5 7 Fichero JSON FileCodificado.json **8**

5.1 7.2 Importación del fichero 8

5.2 7.3 Inspeccion de los datos 9

6 8 Fichero JSON iris_json.json **12**

1 2 Ejemplo: fichero DFP1_11122015 124700.csv

1.1 2.1 Importación del fichero

###1. La diferencia entre importar con readr y base es que base te permite saber que tipo de variable usamos y ademas en base te indica directamente que el separador en un tabulador. Visualmente no encuentro ninguna diferencia más.

###2.

```
dataframe <- "data/DFP1_11122015 124700.csv"

leer <- read.csv(dataframe, sep = "\t", stringsAsFactors = FALSE)
```

###3.

```
#miramoslos nombres y tipos de columnas
names(leer)
```

```
## [1] "FECHA"             "HORA"              "Altura"
## [4] "Combinacion_Canya" "Temperatura"
```

```
str(leer)
```

```
## 'data.frame':    8887 obs. of  5 variables:
##  $ FECHA            : chr  "11/12/2015" "11/12/2015" "11/12/2015" "11/12/2015" ...
##  $ HORA             : chr  "12:47:02" "12:47:02" "12:47:02" "12:47:03" ...
##  $ Altura           : num  138 138 138 138 138 ...
##  $ Combinacion_Canya: num  2 2 2 2 2 2 2 2 2 2 ...
##  $ Temperatura      : num  14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 ...
```

```
#Ahora que sí usamos lo que nos pide sabiendo los nombres

leer$FECHA <- as.POSIXlt(leer$FECHA, format = "%d/%m/%Y")


library(hms)
```

```
## Warning: package 'hms' was built under R version 4.4.3
```

```
leer$Hora <- as.hms(leer$HORA)
```

```
## Warning: `as.hms()` was deprecated in hms 1.2.0.
## i Please use `as_hms()` instead.
## This warning is displayed once per session.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.
```

###4.

```
save(leer, file = "data/results/Dospuntouno.RData")
```

1.2 2.2 Inspeccion de los datos

```
str(leer)
```

```
## 'data.frame':    8887 obs. of  6 variables:
##  $ FECHA            : POSIXlt, format: "2015-12-11" "2015-12-11" ...
##  $ HORA             : chr  "12:47:02" "12:47:02" "12:47:02" "12:47:03" ...
##  $ Altura           : num  138 138 138 138 138 ...
##  $ Combinacion_Canya: num  2 2 2 2 2 2 2 2 2 2 ...
##  $ Temperatura      : num  14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 14.6 ...
##  $ Hora             : 'hms' num  12:47:02 12:47:02 12:47:02 12:47:03 ...
##   ..- attr(*, "units")= chr "secs"
```

Me aporta la estructura del dataframe, numero de columnas, tipos...

```
head(leer)
```

```
##        FECHA     HORA Altura Combinacion_Canya Temperatura     Hora
## 1 2015-12-11 12:47:02 137.81                 2        14.6 12:47:02
## 2 2015-12-11 12:47:02 137.81                 2        14.6 12:47:02
## 3 2015-12-11 12:47:02 137.81                 2        14.6 12:47:02
## 4 2015-12-11 12:47:03 137.81                 2        14.6 12:47:03
## 5 2015-12-11 12:47:03 137.81                 2        14.6 12:47:03
## 6 2015-12-11 12:47:03 137.81                 2        14.6 12:47:03
```

Me aporta las primmeras 6 filas

```
tail(leer)
```

```
##           FECHA     HORA Altura Combinacion_Canya Temperatura     Hora
## 8882 2015-12-11 13:49:41 949.13                 2        14.7 13:49:41
## 8883 2015-12-11 13:49:41 949.13                 2        14.7 13:49:41
## 8884 2015-12-11 13:49:41 949.13                 2        14.7 13:49:41
## 8885 2015-12-11 13:49:41 949.13                 2        14.7 13:49:41
## 8886 2015-12-11 13:49:41 949.13                 2        14.7 13:49:41
## 8887 2015-12-11 13:49:42 949.13                 2        14.7 13:49:42
```

Me aporta las ultimas 6 filas

```
summary(leer)
```

```
##      FECHA                HORA               Altura       Combinacion_Canya
##  Min.   :2015-12-11   Length:8887        Min.   : 137.8   Min.   :1
##  1st Qu.:2015-12-11   Class :character   1st Qu.: 400.9   1st Qu.:1
##  Median :2015-12-11   Mode  :character   Median : 953.1   Median :2
##  Mean   :2015-12-11                      Mean   : 785.8   Mean   :2
##  3rd Qu.:2015-12-11                      3rd Qu.:1079.0   3rd Qu.:3
##  Max.   :2015-12-11                      Max.   :1089.1   Max.   :3
##   Temperatura        Hora
##  Min.   :14.40   Length:8887
##  1st Qu.:14.50   Class1:hms
##  Median :14.60   Class2:difftime
##  Mean   :14.57   Mode  :numeric
##  3rd Qu.:14.60
##  Max.   :14.70
```

Me aporta un resumen de cada columna

2 3 Fichero Transactions from a Bakery

```r
filename <- "data/bakery_sales_revised.csv"

bakery <- read.csv(filename)

str(bakery)
```

```
## 'data.frame':    20507 obs. of  5 variables:
##  $ Transaction    : int  1 2 2 3 3 3 4 5 5 5 ...
##  $ Item           : chr  "Bread" "Scandinavian" "Scandinavian" "Hot chocolate" ...
##  $ date_time      : chr  "10/30/2016 9:58" "10/30/2016 10:05" "10/30/2016 10:05" "10/30/2016 10:07"
##  $ period_day     : chr  "morning" "morning" "morning" "morning" ...
##  $ weekday_weekend: chr  "weekend" "weekend" "weekend" "weekend" ...
```

```r
library(readr)
```

```
## Warning: package 'readr' was built under R version 4.4.3
```

```r
bakery_sales_revised <- read_csv("data/bakery_sales_revised.csv")
```

```
## Rows: 20507 Columns: 5
## -- Column specification --------------------------------------------------------
## Delimiter: ","
## chr (4): Item, date_time, period_day, weekday_weekend
## dbl (1): Transaction
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```r
View(bakery_sales_revised)
```

```r
save(bakery, file = "data/results/Tres.RData")
```

```r
dim(bakery)
```

```
## [1] 20507     5
```

```r
str(bakery)
```

```
## 'data.frame':    20507 obs. of  5 variables:
##  $ Transaction    : int  1 2 2 3 3 3 4 5 5 5 ...
##  $ Item           : chr  "Bread" "Scandinavian" "Scandinavian" "Hot chocolate" ...
##  $ date_time      : chr  "10/30/2016 9:58" "10/30/2016 10:05" "10/30/2016 10:05" "10/30/2016 10:07"
##  $ period_day     : chr  "morning" "morning" "morning" "morning" ...
##  $ weekday_weekend: chr  "weekend" "weekend" "weekend" "weekend" ...
```

```r
head(bakery)
```

```
##   Transaction          Item        date_time period_day weekday_weekend
## 1           1         Bread  10/30/2016 9:58    morning         weekend
## 2           2  Scandinavian 10/30/2016 10:05    morning         weekend
## 3           2  Scandinavian 10/30/2016 10:05    morning         weekend
## 4           3 Hot chocolate 10/30/2016 10:07    morning         weekend
## 5           3           Jam 10/30/2016 10:07    morning         weekend
## 6           3       Cookies 10/30/2016 10:07    morning         weekend
```

```
tail(bakery)
```

```
##       Transaction         Item      date_time period_day weekday_weekend
## 20502        9682 Tacos-Fajita 4/9/2017 14:32  afternoon         weekend
## 20503        9682       Coffee 4/9/2017 14:32  afternoon         weekend
## 20504        9682          Tea 4/9/2017 14:32  afternoon         weekend
## 20505        9683       Coffee 4/9/2017 14:57  afternoon         weekend
## 20506        9683       Pastry 4/9/2017 14:57  afternoon         weekend
## 20507        9684    Smoothies 4/9/2017 15:04  afternoon         weekend
```

```
summary(bakery)
```

```
##   Transaction       Item            date_time          period_day
##  Min.   :   1   Length:20507       Length:20507       Length:20507
##  1st Qu.:2552   Class :character   Class :character   Class :character
##  Median :5137   Mode  :character   Mode  :character   Mode  :character
##  Mean   :4976
##  3rd Qu.:7357
##  Max.   :9684
##  weekday_weekend
##  Length:20507
##  Class :character
##  Mode  :character
##
##
##
```

3 4 Fichero SPSS PyschBike.sav

```
library(haven)
```

```
## Warning: package 'haven' was built under R version 4.4.3
```

```
filename <- "data/PsychBike.sav"

PsychBike <- read_sav(filename)

save(PsychBike, file = "data/results/PsychBike.RData")
```

3.1 Inspección de los datos

```
dim(PsychBike)
```

```
## [1] 2355    6
```

```
str(PsychBike)
```

```
## tibble [2,355 x 6] (S3: tbl_df/tbl/data.frame)
##  $ vehicle           : dbl+lbl [1:2355] 1, 5, 2, 1, 4, 1, 2, 1, 4, 7, 2, 3, 1, 1, 1, 2, 1, 2,...
##    ..@ format.spss: chr "F11.0"
##    ..@ labels     : Named num [1:7] 1 2 3 4 5 6 7
##    .. ..- attr(*, "names")= chr [1:7] "car" "LGV" "SUV" "bus" ...
##  $ Colour            : dbl+lbl [1:2355]  1,  2,  1, 99,  9,  3,  4,  2,  2, 99,  4,  4,  1,  ...
##    ..@ format.spss: chr "F11.0"
##    ..@ labels     : Named num [1:8] 1 2 3 4 5 6 9 99
##    .. ..- attr(*, "names")= chr [1:8] "blue" "red" "silver/grey" "white" ...
##  $ hour              : 'hms' num [1:2355] 16:00:00 16:00:00 16:00:00 16:00:00 ...
##   ..- attr(*, "units")= chr "secs"
##   ..- attr(*, "format.spss")= chr "TIME11.2"
##  $ helmet            : num [1:2355] 0 0 0 0 0 0 1 1 1 1 ...
##   ..- attr(*, "format.spss")= chr "F11.0"
##  $ Distance_from_kerb: num [1:2355] 0.5 0.5 0.5 0.5 0.5 0.5 1 1 1 1 ...
##   ..- attr(*, "label")= chr "Distance from kerb"
##   ..- attr(*, "format.spss")= chr "F11.1"
##  $ Passing_distance  : num [1:2355] 1.864 0.748 1.567 1.39 1.294 ...
##   ..- attr(*, "label")= chr "Passing distance"
##   ..- attr(*, "format.spss")= chr "F11.3"
```

```
head(PsychBike)
```

```
## # A tibble: 6 x 6
##   vehicle   Colour          hour   helmet Distance_from_kerb Passing_distance
##   <dbl+lbl> <dbl+lbl>       <time>  <dbl>              <dbl>            <dbl>
## 1 1 [car]    1 [blue]       16:00       0                0.5             1.86
## 2 5 [HGV]    2 [red]        16:00       0                0.5             0.748
## 3 2 [LGV]    1 [blue]       16:00       0                0.5             1.57
## 4 1 [car]   99 [unknown]    16:00       0                0.5             1.39
## 5 4 [bus]    9 [other]      16:00       0                0.5             1.29
## 6 1 [car]    3 [silver/grey] 16:00      0                0.5             1.26
```

```
tail(PsychBike)
```

```
## # A tibble: 6 x 6
##   vehicle   Colour          hour   helmet Distance_from_kerb Passing_distance
##   <dbl+lbl> <dbl+lbl>       <time>  <dbl>              <dbl>            <dbl>
## 1 2 [LGV]    9 [other]      10:00       1               1.25             1.10
## 2 1 [car]    3 [silver/grey] 10:00      1               1.25             1.01
## 3 1 [car]    2 [red]        10:00       1               1.25             0.922
## 4 5 [HGV]    4 [white]      10:00       1               1.25             0.564
## 5 1 [car]    1 [blue]       10:00       1               1.25             0.65
## 6 1 [car]    6 [green]      10:00       1               1.25             0.781
```

```r
summary(PsychBike)
```

```
##     vehicle          Colour           hour              helmet
##  Min.   :1.000   Min.   : 1.000   Length:2355       Min.   :0.0000
##  1st Qu.:1.000   1st Qu.: 1.000   Class1:hms        1st Qu.:0.0000
##  Median :1.000   Median : 3.000   Class2:difftime   Median :0.0000
##  Mean   :1.634   Mean   : 3.556   Mode  :numeric    Mean   :0.4879
##  3rd Qu.:2.000   3rd Qu.: 4.000                     3rd Qu.:1.0000
##  Max.   :7.000   Max.   :99.000                     Max.   :1.0000
##  Distance_from_kerb Passing_distance
##  Min.   :0.2500     Min.   :0.144
##  1st Qu.:0.2500     1st Qu.:1.053
##  Median :0.5000     Median :1.279
##  Mean   :0.6702     Mean   :1.314
##  3rd Qu.:1.0000     3rd Qu.:1.540
##  Max.   :1.2500     Max.   :3.537
```

4 5 Fichero data iris.zip

4.1 5.1 Descompimir el fichero

```r
unzip("data/iris.zip", exdir = "data")
```

#6 Fcihero data iris.data

##6.1 Importación del fichero

```r
Ejer6 <- read.table("data/iris.data")
```

2.

```r
names(iris) <- c(
  "Sepal.Length",
  "Sepal.Width",
  "Petal.Length",
  "Petal.Width",
  "Species"
)
```

3.

```r
save(iris, file = "data/results/iris.RData")
```

4.

```r
str(iris)
```

```
## 'data.frame':    150 obs. of  5 variables:
##  $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
##  $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
##  $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
##  $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
##  $ Species     : Factor w/ 3 levels "setosa","versicolor",..: 1 1 1 1 1 1 1 1 1 1 ...
```

```
head(iris)
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1          5.1         3.5          1.4         0.2  setosa
## 2          4.9         3.0          1.4         0.2  setosa
## 3          4.7         3.2          1.3         0.2  setosa
## 4          4.6         3.1          1.5         0.2  setosa
## 5          5.0         3.6          1.4         0.2  setosa
## 6          5.4         3.9          1.7         0.4  setosa
```

```
tail(iris)
```

```
##     Sepal.Length Sepal.Width Petal.Length Petal.Width   Species
## 145          6.7         3.3          5.7         2.5 virginica
## 146          6.7         3.0          5.2         2.3 virginica
## 147          6.3         2.5          5.0         1.9 virginica
## 148          6.5         3.0          5.2         2.0 virginica
## 149          6.2         3.4          5.4         2.3 virginica
## 150          5.9         3.0          5.1         1.8 virginica
```

```
summary(iris)
```

```
##   Sepal.Length    Sepal.Width     Petal.Length    Petal.Width
##  Min.   :4.300   Min.   :2.000   Min.   :1.000   Min.   :0.100
##  1st Qu.:5.100   1st Qu.:2.800   1st Qu.:1.600   1st Qu.:0.300
##  Median :5.800   Median :3.000   Median :4.350   Median :1.300
##  Mean   :5.843   Mean   :3.057   Mean   :3.758   Mean   :1.199
##  3rd Qu.:6.400   3rd Qu.:3.300   3rd Qu.:5.100   3rd Qu.:1.800
##  Max.   :7.900   Max.   :4.400   Max.   :6.900   Max.   :2.500
##        Species
##  setosa    :50
##  versicolor:50
##  virginica :50
##
##
##
```

5 7 Fichero JSON FileCodificado.json

5.1 7.2 Importación del fichero

```r
library(jsonlite)
```

```
## Warning: package 'jsonlite' was built under R version 4.4.3
```

```r
jason <- "data/FileCodificado.json"


datos_json <- read_json(jason, simplifyVector = TRUE)

str(datos_json)
```

```
## 'data.frame':    83 obs. of  22 variables:
##  $ Carburante             : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ Potencia               : int  60 60 60 60 60 60 60 60 60 60 ...
##  $ Servicio_Vehiculo      : chr  "B00" "B00" "B00" "B00" ...
##  $ Actividad_Vehiculo     : chr  "D" "D" "D" "D" ...
##  $ GAMA                   : chr  "UTILITARIO" "UTILITARIO" "UTILITARIO" "UTILITARIO" ...
##  $ Unidades_Matriculadas  : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Localidad_definitiva   : chr  "ALGECIRAS" "ALGECIRAS" "ALGECIRAS" "ALGECIRAS" ...
##  $ Provincia_definitiva   : chr  "CADIZ" "CADIZ" "CADIZ" "CADIZ" ...
##  $ Codigo_Postal          : num  0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.029
##  $ Viviendas              : num  0.12 0.12 0.12 0.12 0.12 ...
##  $ precio_medio_m2        : num  0.18 0.18 0.18 0.18 0.18 ...
##  $ Peso_vivienda          : int  2 2 2 2 2 2 2 2 2 2 ...
##  $ RAISON_SOCIAL          : chr  "ALGECIREÑA DE MOTOR E INV., S.L." "ALGECIREÑA DE MOTOR E INV., S.L
##  $ RUE_SSOC               : chr  "Ctra. a Malaga, Km. 108" "Ctra. a Malaga, Km. 108" "Ctra. a Malaga
##  $ Edad_Conductor         : chr  "18 a 20 años" "21 a 24 años" "25 a 29 años" "30 a 34 años" ...
##  $ Numero de Conductores  : num  0.0132 0.0569 0.1086 0.1392 0.1706 ...
##  $ Antigüedad             : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Anos_Antiguedad        : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Numero_vehiculos_parque: int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Cluster_GamaPotencia   : chr  "cluster_1_GamaPotencia" "cluster_1_GamaPotencia" "cluster_1_GamaPo
##  $ Cluster_Antiguedad     : chr  "cluster_1_Antiguedad" "cluster_1_Antiguedad" "cluster_1_Antiguedad
##  $ Cluster_Edad           : chr  "cluster_3_Edad" "cluster_3_Edad" "cluster_3_Edad" "cluster_3_Edad"
```

```r
save(datos_json, file = "data/results/FileCodificado.RData")
```

5.2 7.3 Inspeccion de los datos

```r
str(datos_json)
```

```
## 'data.frame':    83 obs. of  22 variables:
##  $ Carburante             : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ Potencia               : int  60 60 60 60 60 60 60 60 60 60 ...
##  $ Servicio_Vehiculo      : chr  "B00" "B00" "B00" "B00" ...
##  $ Actividad_Vehiculo     : chr  "D" "D" "D" "D" ...
##  $ GAMA                   : chr  "UTILITARIO" "UTILITARIO" "UTILITARIO" "UTILITARIO" ...
##  $ Unidades_Matriculadas  : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Localidad_definitiva   : chr  "ALGECIRAS" "ALGECIRAS" "ALGECIRAS" "ALGECIRAS" ...
```

```
##  $ Provincia_definitiva   : chr  "CADIZ" "CADIZ" "CADIZ" "CADIZ" ...
##  $ Codigo_Postal          : num  0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.0297 0.029
##  $ Viviendas              : num  0.12 0.12 0.12 0.12 0.12 ...
##  $ precio_medio_m2        : num  0.18 0.18 0.18 0.18 0.18 ...
##  $ Peso_vivienda          : int  2 2 2 2 2 2 2 2 2 2 ...
##  $ RAISON_SOCIAL          : chr  "ALGECIREÑA DE MOTOR E INV., S.L." "ALGECIREÑA DE MOTOR E INV., S.L
##  $ RUE_SSOC               : chr  "Ctra. a Malaga, Km. 108" "Ctra. a Malaga, Km. 108" "Ctra. a Malaga
##  $ Edad_Conductor         : chr  "18 a 20 años" "21 a 24 años" "25 a 29 años" "30 a 34 años" ...
##  $ Numero de Conductores  : num  0.0132 0.0569 0.1086 0.1392 0.1706 ...
##  $ Antigüedad             : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Anos_Antiguedad        : int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Numero_vehiculos_parque: int  0 0 0 0 0 0 0 0 0 0 ...
##  $ Cluster_GamaPotencia   : chr  "cluster_1_GamaPotencia" "cluster_1_GamaPotencia" "cluster_1_GamaPo
##  $ Cluster_Antiguedad     : chr  "cluster_1_Antiguedad" "cluster_1_Antiguedad" "cluster_1_Antiguedad
##  $ Cluster_Edad           : chr  "cluster_3_Edad" "cluster_3_Edad" "cluster_3_Edad" "cluster_3_Edad"
```

```
head(datos_json)
```

```
##   Carburante Potencia Servicio_Vehiculo Actividad_Vehiculo       GAMA
## 1          1       60               B00                  D UTILITARIO
## 2          1       60               B00                  D UTILITARIO
## 3          1       60               B00                  D UTILITARIO
## 4          1       60               B00                  D UTILITARIO
## 5          1       60               B00                  D UTILITARIO
## 6          1       60               B00                  D UTILITARIO
##   Unidades_Matriculadas Localidad_definitiva Provincia_definitiva Codigo_Postal
## 1                     0           ALGECIRAS                CADIZ        0.0297
## 2                     0           ALGECIRAS                CADIZ        0.0297
## 3                     0           ALGECIRAS                CADIZ        0.0297
## 4                     0           ALGECIRAS                CADIZ        0.0297
## 5                     0           ALGECIRAS                CADIZ        0.0297
## 6                     0           ALGECIRAS                CADIZ        0.0297
##   Viviendas precio_medio_m2 Peso_vivienda                  RAISON_SOCIAL
## 1    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 2    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 3    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 4    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 5    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
## 6    0.1201          0.1799             2 ALGECIREÑA DE MOTOR E INV., S.L.
##                 RUE_SSOC Edad_Conductor Numero de Conductores Antigüedad
## 1 Ctra. a Malaga, Km. 108   18 a 20 años               0.0132          0
## 2 Ctra. a Malaga, Km. 108   21 a 24 años               0.0569          0
## 3 Ctra. a Malaga, Km. 108   25 a 29 años               0.1086          0
## 4 Ctra. a Malaga, Km. 108   30 a 34 años               0.1392          0
## 5 Ctra. a Malaga, Km. 108   35 a 39 años               0.1706          0
## 6 Ctra. a Malaga, Km. 108   40 a 44 años               0.1577          0
##   Anos_Antiguedad Numero_vehiculos_parque   Cluster_GamaPotencia
## 1               0                       0 cluster_1_GamaPotencia
## 2               0                       0 cluster_1_GamaPotencia
## 3               0                       0 cluster_1_GamaPotencia
## 4               0                       0 cluster_1_GamaPotencia
## 5               0                       0 cluster_1_GamaPotencia
## 6               0                       0 cluster_1_GamaPotencia
##     Cluster_Antiguedad   Cluster_Edad
```

```
## 1 cluster_1_Antiguedad cluster_3_Edad
## 2 cluster_1_Antiguedad cluster_3_Edad
## 3 cluster_1_Antiguedad cluster_3_Edad
## 4 cluster_1_Antiguedad cluster_3_Edad
## 5 cluster_1_Antiguedad cluster_3_Edad
## 6 cluster_1_Antiguedad cluster_3_Edad
```

```
tail(datos_json)
```

```
##    Carburante Potencia Servicio_Vehiculo Actividad_Vehiculo       GAMA
## 78          1       60               B00                  D UTILITARIO
## 79          1       60               B00                  D UTILITARIO
## 80          1       60               B00                  D UTILITARIO
## 81          1       60               B00                  D UTILITARIO
## 82          1       60               B00                  D UTILITARIO
## 83          1       60               B00                  D UTILITARIO
##    Unidades_Matriculadas    Localidad_definitiva Provincia_definitiva
## 78                     0 CHICLANA DE LA FRONTERA                CADIZ
## 79                     0 CHICLANA DE LA FRONTERA                CADIZ
## 80                     0 CHICLANA DE LA FRONTERA                CADIZ
## 81                     0 CHICLANA DE LA FRONTERA                CADIZ
## 82                     0 CHICLANA DE LA FRONTERA                CADIZ
## 83                     0 CHICLANA DE LA FRONTERA                CADIZ
##    Codigo_Postal Viviendas precio_medio_m2 Peso_vivienda          RAISON_SOCIAL
## 78         0.028    0.1132          0.4255             3       RAMON HOYO, S.L.
## 79         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
## 80         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
## 81         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
## 82         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
## 83         0.028    0.1132          0.4255             3 TALLERES COLCHÓN, S.L.
##                    RUE_SSOC Edad_Conductor Numero de Conductores Antigüedad
## 78 AVDA. REYES CATOLICOS, 5 Más de 74 años                0.0098          0
## 79               Caraza, 33   18 a 20 años                0.0099          0
## 80               Caraza, 33   21 a 24 años                0.0321          0
## 81               Caraza, 33   25 a 29 años                0.0793          0
## 82               Caraza, 33   30 a 34 años                0.0946          0
## 83               Caraza, 33   35 a 39 años                0.1150          0
##    Anos_Antiguedad Numero_vehiculos_parque   Cluster_GamaPotencia
## 78               0                       0 cluster_1_GamaPotencia
## 79               0                       0 cluster_1_GamaPotencia
## 80               0                       0 cluster_1_GamaPotencia
## 81               0                       0 cluster_1_GamaPotencia
## 82               0                       0 cluster_1_GamaPotencia
## 83               0                       0 cluster_1_GamaPotencia
##      Cluster_Antiguedad   Cluster_Edad
## 78 cluster_6_Antiguedad cluster_3_Edad
## 79 cluster_1_Antiguedad cluster_3_Edad
## 80 cluster_1_Antiguedad cluster_3_Edad
## 81 cluster_1_Antiguedad cluster_3_Edad
## 82 cluster_1_Antiguedad cluster_3_Edad
## 83 cluster_1_Antiguedad cluster_3_Edad
```

```r
summary(datos_json)
```

```
##    Carburante    Potencia  Servicio_Vehiculo  Actividad_Vehiculo
##  Min.   :1    Min.   :60   Length:83          Length:83
##  1st Qu.:1    1st Qu.:60   Class :character   Class :character
##  Median :1    Median :60   Mode  :character   Mode  :character
##  Mean   :1    Mean   :60
##  3rd Qu.:1    3rd Qu.:60
##  Max.   :1    Max.   :60
##      GAMA           Unidades_Matriculadas Localidad_definitiva
##  Length:83          Min.   :0             Length:83
##  Class :character   1st Qu.:0             Class :character
##  Mode  :character   Median :0             Mode  :character
##                     Mean   :0
##                     3rd Qu.:0
##                     Max.   :0
##  Provincia_definitiva Codigo_Postal      Viviendas      precio_medio_m2
##  Length:83            Min.   :0.0280   Min.   :0.1132   Min.   :0.1799
##  Class :character     1st Qu.:0.0280   1st Qu.:0.1132   1st Qu.:0.1799
##  Mode  :character     Median :0.0280   Median :0.1132   Median :0.4255
##                       Mean   :0.1003   Mean   :0.1487   Mean   :0.3761
##                       3rd Qu.:0.0297   3rd Qu.:0.1201   3rd Qu.:0.4255
##                       Max.   :0.4860   Max.   :0.3258   Max.   :0.6015
##  Peso_vivienda   RAISON_SOCIAL        RUE_SSOC         Edad_Conductor
##  Min.   :2.000   Length:83          Length:83          Length:83
##  1st Qu.:2.000   Class :character   Class :character   Class :character
##  Median :3.000   Mode  :character   Mode  :character   Mode  :character
##  Mean   :2.843
##  3rd Qu.:3.000
##  Max.   :4.000
##  Numero de Conductores   Antigüedad Anos_Antiguedad Numero_vehiculos_parque
##  Min.   :0.00740       Min.   :0    Min.   :0       Min.   :0
##  1st Qu.:0.02720       1st Qu.:0    1st Qu.:0       1st Qu.:0
##  Median :0.06250       Median :0    Median :0       Median :0
##  Mean   :0.06731       Mean   :0    Mean   :0       Mean   :0
##  3rd Qu.:0.10035       3rd Qu.:0    3rd Qu.:0       3rd Qu.:0
##  Max.   :0.17060       Max.   :0    Max.   :0       Max.   :0
##  Cluster_GamaPotencia Cluster_Antiguedad Cluster_Edad
##  Length:83            Length:83          Length:83
##  Class :character     Class :character   Class :character
##  Mode  :character     Mode  :character   Mode  :character
##
##
##
```

6 8 Fichero JSON iris_json.json

##8.1 Importar el fichero iris_json.json

```r
ocho <- "data/iris_json.json"
```

```
iris_read <- read_json(ocho, simplifyVector = TRUE)

iris_from <- fromJSON(ocho)

str(iris_read)
```

```
## 'data.frame':    150 obs. of  5 variables:
##  $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
##  $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
##  $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
##  $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
##  $ Species     : chr  "setosa" "setosa" "setosa" "setosa" ...
```

```
str(iris_from)
```

```
## 'data.frame':    150 obs. of  5 variables:
##  $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
##  $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
##  $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
##  $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
##  $ Species     : chr  "setosa" "setosa" "setosa" "setosa" ...
```

```
save(iris_from, file = "data/results/iris_json.RData")
```

La única diferencia que encuentro esque read_json es necesario usar simplifyVector y en fromJSON viene ya predeterminado

##8.2 Inspeccion de datos

```
str(iris_from)
```

```
## 'data.frame':    150 obs. of  5 variables:
##  $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
##  $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
##  $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
##  $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
##  $ Species     : chr  "setosa" "setosa" "setosa" "setosa" ...
```

```
head(iris_from)
```

```
##   Sepal.Length Sepal.Width Petal.Length Petal.Width Species
## 1          5.1         3.5          1.4         0.2  setosa
## 2          4.9         3.0          1.4         0.2  setosa
## 3          4.7         3.2          1.3         0.2  setosa
## 4          4.6         3.1          1.5         0.2  setosa
## 5          5.0         3.6          1.4         0.2  setosa
## 6          5.4         3.9          1.7         0.4  setosa
```

```
tail(iris_from)
```

```
##     Sepal.Length Sepal.Width Petal.Length Petal.Width   Species
## 145          6.7         3.3          5.7         2.5 virginica
## 146          6.7         3.0          5.2         2.3 virginica
## 147          6.3         2.5          5.0         1.9 virginica
## 148          6.5         3.0          5.2         2.0 virginica
## 149          6.2         3.4          5.4         2.3 virginica
## 150          5.9         3.0          5.1         1.8 virginica
```

```
summary(iris_from)
```

```
##   Sepal.Length    Sepal.Width     Petal.Length    Petal.Width
##  Min.   :4.300   Min.   :2.000   Min.   :1.000   Min.   :0.100
##  1st Qu.:5.100   1st Qu.:2.800   1st Qu.:1.600   1st Qu.:0.300
##  Median :5.800   Median :3.000   Median :4.350   Median :1.300
##  Mean   :5.843   Mean   :3.057   Mean   :3.758   Mean   :1.199
##  3rd Qu.:6.400   3rd Qu.:3.300   3rd Qu.:5.100   3rd Qu.:1.800
##  Max.   :7.900   Max.   :4.400   Max.   :6.900   Max.   :2.500
##    Species
##  Length:150
##  Class :character
##  Mode  :character
##
##
##
```

##8.3 exportar datos en formato JSON

1.

```
load("data/results/iris.RData")

write_json(iris,"data/iris_json_v2.json")
```

2.

```
library(jsonlite)
library(readr)

data(iris)

json1 <- toJSON(iris)

write_file(json1, "data/iris_json_v2.json")

json2 <- toJSON(iris, pretty = TRUE)

write_file(json2, "data/iris_json_pretty.json")
```

El parámetro pretty te ordena el jason en bloques, si no ponemos el pretty y abres el archivo entonces saldría todo en una linea